Benchmarking dos Resultados Obtidos com IOZone, e a Framework Dtrace

Sérgio Caldas
Universidade do Minho
Escola de Engenharia
Departamento de Informática
Email: a57779@alunos.uminho.pt

Resumo—Neste trabalho, desenvolvido no âmbito da disciplina de Engenharia de Sistemas de Computação (ESC), inserida no perfil de Computação Paralela e Distribuída (CPD) do curso de Engenharia Informática, tem como objetivo estudar uma variada gama de testes, constituintes do IOZone Benchmark. Este Benchmark, é usado para fazer testes de performance de Filesystems. Depois de definidos os testes que vou usar, posteriormente, tenho de confirmar esses resultados com a ferramenta Dtrace, criando diversas scripts que irão fazer traçados dinâmicos de forma a obter os mesmos resultados que foram obtidos na execução do IOZone Benchmark.

1. Introdução

Benchmark [2] é o ato de executar um conjunto de testes padrão de forma a avaliar o desempenho quer de Hardware quer de Software. O Benchmark é muito usado na área de ciências de computação, sendo que o Benchmark se divide em "Passivo" e "Activo" [1]. O Benchmark "Passivo", diz respeito à execução de um conjunto de testes padrão, sendo que estes são ignorados até que terminem. O principal objetivo deste tipo de Benchmark é obter dados de referência de forma a poder comprovar/comparar com outros resultados. Com o Benchmark "Activo", testa-se a performance do Benchmark enquanto este corre, com isto podemos ver o que testa o Benchmark bem como perceber a maneira como o Benchmark se comporta, aqui os dados são informação.

Com a resolução deste trabalho, é suposto fazer *Benchmark* "Activo" ao *Filesystem* (no meu caso) da máquina *Solaris 11*, recorrendo a diversos testes do *IOZone Benchmark* e à ferramenta *Dtrace*.

Os testes que irei efectuar baseiam-se sobretudo na análise de operações, tais como, *Read, write, re-read, re-write*.

Depois de efetuados os testes em cima referidos, utilizarei a *Framework DTrace*, com a criação de diversas scripts em *D* capazes de calcular os mesmos resultados que foram obtidos com o *IOZone Benchmark*, por forma a poder comparar/comprovar os dois resultados.

2. Ferramentas Utilizadas

Na realização deste trabalho, para além do *IOZone Benchmark*, irão ser utilizadas mais duas ferramentas, a ferramenta *DTrace* e a ferramenta *truss* (ferramenta equivalente ao *strace* contudo é usada em *Solaris*).

O DTrace é uma Framework que permite fazer traçados dinâmicos, esta é usada para solucionar problemas no Kernel e aplicações em produção, em tempo real. O Dtrace pode ser utilizado para se obter uma visão geral da execução do sistema, como a quantidade de memória, o tempo de CPU, os recursos usados por os processos activos. Esta Framework permite fazer traçados muito mais rebuscados e detalhados, tais como, por exemplo a lista de processos que tenta aceder a um ficheiro.

No âmbito deste trabalho a *Framework DTrace*, é utilizada (através do uso *Scripts* em *D*) com o intuito de se obter os mesmos (ou aproximadamente os mesmos) resultados que se obteve com o *IOZone Benchmark*, por forma a confirmar/comparar esses resultados.

A ferramenta/comando *truss*, é uma ferramenta que executa um determinado comando e produz um traçado de todas as chamadas ao sistema que esse comando produz, os sinais que o comando recebe, e as falhas da máquina que ocorrem. Cada linha do *output* retorna a falha ou o nome do sinal ou o nome da chamada ao sistema com os argumentos e valores de retorno.

No âmbito deste trabalho, a ferramenta *truss* é usada de forma a nos ajudar a compreender o comportamento de toda a aplicação que estamos a executar (neste caso o *IOZone Benchmark*), ver quais as chamadas ao sistema utilizadas pela a aplicação, bem como os sinais e falhas que esta produz. Basicamente esta ferramenta é usada apenas como forma de estudar o comportamento do *Benchmark*.

3. IOZone Benchmark

O *IOZone* é uma ferramenta de *Benchmark* para *Filesystem's*, com este *benchmark* é possível gerar e medir uma grande variedade de operações, esta ferramenta foi adaptada para diversos sistemas, correndo em diversos sistemas operativos.

O *IOZone* é util para determinar uma basta gama de análises sobre um *Filesystem* de um determinada plataforma

de um determinado vendedor. Este *Benchmark* testa o desempenho de ficheiros I/O para as seguintes operações:

- read;
- write;
- re-read;
- re-write;
- read backwards;
- read strided;
- fread;
- fwrite;
- random read/write;
- pread/pwrite variants;
- aio_read;
- aio_write;
- mmap.

Com o uso deste *Benchmark*, obtemos uma grande gama de fatores de desempenho relativos ao *Filesystem*, com isto o cliente consegue ver os pontos fortes e fracos de uma plataforma e de um sistema operativo e tomar uma decisão mais equilibrada quanto a sua escolha.

4. Testes/Flags a Realizar/Usar com IOZone

Para correr o *IOZone Benchmark*, executa-se o seguinte comando, juntamente, com as *flags* que desejarmos.

/opt/csw/bin/iozone

Nesta secção, irei apresentar todos os testes que pretendo realizar com o *Benchmark IOZone* [3], bem como as *Flags* que pretendo usar na execução do *Benchmark*. Todos os resultados do *IOZone Benchmark* são em Kbytes/sec.

As Flags que irei usar são as seguintes:

- I Esta flag usa DIRECT I/O para todas as operações de ficheiros. Diz ao Filesystem, para todas as operações ignorar o buffer cache e ir diretamente ao disco:
- a Esta flag é usada para ativar o modo automático, basicamente, esta flag ativa todos os testes disponíveis do Benchmark:
- -r# Esta flag é usada para definir o tamanho do registo, podemos usar -r#k (tamanho em Kbytes), -r#m (tamanho em Mbytes), -r#g (tamanho em Gbytes);
- -s# Esta flag é usada para definir o tamanho do ficheiro a testar, podemos usar -s#k (tamanho em Kbytes), -s#m (tamanho em Mbytes), -s#g (tamanho em Gbytes);
- -t# Executa o Benchmark com throughput mode.
 Esta opção permite ao utilizador especificar quantas Threads ou Processos pretende ativar durante os testes;

No que toca aos testes, apresento em baixo todos os que pretendo realizar:

Write e Rewrite - para este teste é usado a flag -i0.
 O comando completo pode ser consultado em baixo

para um ficheiro de 10 Mb com um *Record Size* de 64 Kb:

/opt/csw/bin/iozone -i0 -r64k -s10m

- Write mede a performance de escrever um ficheiro novo, quando um ficheiro é escrito, não é só os dados que são escritos mas também "meta-dados". Estes "metadados" contém informação que permite controlar onde os dados estão armazenados nas unidades físicas de armazenamento. Estes meta-dados contém informação da diretoria e do espaço alocado entre outros dados;
- Rewrite Este teste mede a performance de escrever um ficheiro já existente. Quando um ficheiro existente é escrito, o trabalho necessário é menor uma vez que os "metadados" já existem. É normal a performance de rescrever um ficheiro já existente ser maior que a performance de escrever um ficheiro novo.

O output produzido pelo comando apresentado em cima foi:

```
Record Size 64 kB

File size set to 10240 kB

Command line used: /opt/csw/bin/iozone -i0 -r64k -s10m

Output is in kBytes/sec

Time Resolution = 0.000001 seconds.

Processor cache size set to 1024 kBytes.

Frocessor cache line size set to 32 bytes.

File stride size set to 17 * record size.

KB reclen write rewrite

10240 64 119047 119346
```

Como podemos verificar pelo *output* em cima, o *Record Size* é de 64 kB e o tamanho do ficheiro é de 10240 kB ou seja 10 Mb. Quanto aos resultados obtidos vemos que as operações de escrita num novo ficheiro (*write*) foram feitas a uma velocidade de 119047 kBytes/sec e as operações de escrita num ficheiro já existente (*Rewrite*) foram feitas a uma velocidade de 119346 kBytes/sec.

Read e Reread - para este teste é usado a flag -i1.
 O comando completo pode ser consultado em baixo para um ficheiro de 10 Mb com um Record Size de 64 Kb:

/opt/csw/bin/iozone -i1 -r64k -s10m

- Read Este teste mede a performance de leitura de um ficheiro já existente;
- Reread Este teste mede a performance de leitura de um ficheiro que foi lido recentemente. É normal a performance ser maior uma vez que o sistema operativo mantém em cache os dados dos arquivos que foram lidos recentemente. Esta cache pode ser usada para satisfazer as leituras e melhorar a performance.

O output produzido pelo comando apresentado em cima foi:

```
Record Size 64 kB
File size set to 10240 kB
Command line used: /opt/csw/bin/iozone -i0 -i1 -r64k -s10m
Output is in kBytes/sec
Time Resolution = 0.000001 seconds.
Processor cache size set to 1024 kBytes.
Processor cache line size set to 32 bytes.
File stride size set to 17 * record size.

KB reclen write rewrite read reread
10240 64 118673 119714 2637083 3101102
```

Como podemos verificar pelo *output* em cima, o *Record Size* é de 64 kB e o tamanho do ficheiro é de 10240 kB ou seja 10 Mb. Quanto aos resultados obtidos vemos que as operações de leitura de um ficheiro já existente (*read*) foram feitas a uma velocidade de 2637083 kBytes/sec e as operações de escrita de um ficheiro lido recentemente (*Reread*) foram feitas a uma velocidade de 3101102 kBytes/sec. Como podemos verificar a velocidade das operações *Reread* é mais elevada, o que já era de se esperar, visto que o sistema operativo mantém em *cache* os dados de arquivos lidos recentemente o que melhora a performance.

5. Análise dos Resultados

Nesta secção irei apresentar os resultados que obtive com a execução do *Benchmark IOZone* para diferentes testes, bem como o *output* produzido pelas *scripts* que desenvolvi em *D*. Os testes foram realizados por etapas, a primeira etapa testei as *Syscall's write* e *Rewrite* e na segunda etapa testei *Syscall's read* e *reread*.

5.1. Write e Rewrite - Testado na Home

Para testar a *Syscall write* (rewrite) na home, usa um sistema de ficheiros *ZFS*, executei o seguinte comando:

```
/opt/csw/bin/iozone -i0 -s10m
```

sendo que o seu output foi o seguinte:

```
File size set to 10240 kB

Command line used: /opt/csw/bin/iozone -i0 -s10m

Output is in kBytes/sec

Time Resolution = 0.000001 seconds.

Processor cache size set to 1024 kBytes.

Processor cache line size set to 32 bytes.

File stride size set to 17 * record size.

KB reclen write rewrite

10240 4 179488 391934
```

A *script* em *D* por mim desenvolvida e que posteriormente foi executada com *Framework Dtrace* pode ser consultada em baixo:

```
#!/usr/sbin/dtrace -s
#pragma D option quiet

syscall::open*:entry
/execname=="iozone" & uid==29231/
{
    self->path = copyinstr(argl);
```

Depois de executada a *script* em cima apresentada, esta apresentou o seguinte *output*:

Ao analisarmos estes resultados podemos constatar que os valores se encontram num intervalo aceitável relativamente aos resultados do *Benchmark IOZone*. Ora vejamos, o tamanho (*SIZE*) encontra-se já em *Kbytes* e o tempo (*ELAPSED TIME*) encontra-se em nanosegundos, por isso necessito converter para segundos, para isso fiz $50946670*10^{-9}=0.05094667$, por fim para se obter o resultado pretendido (*Kb/sec*) fiz: 10240/0.05094667=200994.49091Kb/sec. Como podemos verificar este valor encontra-se entre um intervalo aceitável (179488 \leq 200994.49091 \leq 391934).

Com isto podemos concluir que o *Benchmark IOZone* inicia a contagem do tempo sempre que executa a *syscall open* e termina sempre que executa a *syscall close*. A contagem dos *Bytes* escritos é feita sempre à entrada da *syscall write*.

De referir que este valor obtido através da *script* em *D* contém um erro relativo ao tamanho, uma vez que a medida que se aumenta o tamanho dos ficheiros, os valores resultantes apresentam valores com uma margem de erro maior.

5.2. Write e Rewrite - Testado na diretoria diskHitachi

Para testar o *Benchmark IOZone* no disco HDD (*diskHitachi*) tive de correr o seguinte comando, de referir que tive de usar a *flag -f* para redirecionar o ficheiro temporário para o disco referido.

```
/opt/csw/bin/iozone -f /diskHitachi/a57779/iozone.tmp -i0 -s10m
```

o qual teve o seguinte output:

```
File size set to 10240 kB

Command line used: /opt/csw/bin/iozone —f /diskHitachi/a57779/iozone. ←→
tmp —io —s10m

Output is in kBytes/sec

Time Resolution = 0.000001 seconds.
Processor cache size set to 1024 kBytes.
Processor cache line size set to 32 bytes.
File stride size set to 17 * record size.

KB reclen write rewrite

10240 4 126864 340835
```

Em simultâneo foi executada a seguinte *Script* com o dtrace, de notar também que no predicado em que verifico o *path* (*self->path*) também tive de por a diretoria do disco em causa.

```
#!/usr/sbin/dtrace -s
#pragma D option quict

syscall::open*:entry
/execname=="iozone" & uid==29231/
{
    self->path = copyinstr(argl);
}

syscall::open*:return
/self->path=="/diskHitachi/a57779/iozone.tmp"/
{
    total_time=0;
    size = 0;
    flag = 1;
}

syscall::write:entry
/flag = 1/
{
    self->start_time = timestamp;
    self->w_size = (arg2/1024);
    size = size + self->w_size;
}

syscall::write:return
/self->start_time > 0 & self->w_size > 0/
{
    self->stop_time = timestamp;
    self->self->start_time;
    total_time = total_time + self->elapsed;
}

syscall::close*:entry
/self->path=="/diskHitachi/a57779/iozone.tmp"/
{
    printf("%-128 %s\n", "SIZE", "ELAPSED TIME");
    printf("%-128 %d\n", size,total_time);
    flag = 0;
}
```

O Output da execução da script com a Framework Dtrace foi o seguinte:

Ao analisarmos os dados da mesma maneira que analisei em cima, isto é fazendo os mesmos cálculos que efectuei em cima, obtive os seguintes resultados:

```
• Tempo: 74204464 * 10^{-9} = 0.074204464sec
```

• Kb/sec: 10240/0.047833799 137997.08869*Kb/sec*

Como podemos verificar o valor resultante é um valor que se encontra dentro de um intervalo aceitável, comparado com os resultados do Benchmark IOZone, isto é $126864 \le 137997.08869 < 340835$.

Os discos SSD em termos de escrita têm um desempenho idêntico a um disco HDD, dai as operações de escrita do disco HDD (*diskHitachi*) serem semelhantes às do disco SSD (teste *Home*).

5.3. Read e Reread - Testado na Home

Para testar a *Syscall read (reread)*, executei o seguinte comando:

```
/opt/csw/bin/iozone -i0 -i1 -s10m
```

sendo que o seu output foi o seguinte:

Quanto a *script* em *D* por mim desenvolvida, para o la traçado da *syscall read*, que posteriormente foi executada for the com *Framework Dtrace* pode ser consultada em baixo:

```
19
20
21
22
23
24
25
26
27
28
29
30
31
32
33
34
35
36
37
38
40
41
42
    #!/usr/sbin/dtrace -s
    #pragma D option quiet
    syscall::open*:entry
                                                                                                                                           /execname=="iozone" & uid==29231/
                self->path = copyinstr(arg1);
self->flag = arg2;
    syscall::open*:return
     /self->path=="iozone.tmp" /
                 self->start_time = timestamp;
total_time=0;
size = 0;
                 total\_time\_io = 0;
    syscall::read:return
/self->start_time> 0/
                 self \rightarrow r size = (arg0/1024):
    syscall::close*:entry
/self->path=="iozone.tmp" /
                 self->stop time = timestamp;
                self->slapsed = self->stop_time - self->start_time;
total_time = total_time + self->elapsed;
printf("%-12s %s\n","SIZE","ELAPSED TIME");
                 printf("%-12d %d\n", size, total time);
```

Sendo que o *output* por ela calculado foi o seguinte:

```
FLAPSED TIME
0
SIZE
                ELAPSED TIME
                2023
SIZE
0
                 ELAPSED TIME
                67259606
                                                                                                         6
7
8
9
10
11
12
13
SIZE
0
                ELAPSED TIME
                134527857
SIZE
                ELAPSED TIME
53422605
SIZE
                ELAPSED TIME
10244
                8397888
                ELAPSED TIME
10244
                8219413
```

Ao analisarmos estes resultados podemos constatar que os valores aproximam dos resultados do *Benchmark IOZone*. Ora vejamos, o tamanho (*SIZE*) encontra-se já em *Kbytes* e o tempo (*ELAPSED TIME*) encontra-se em nanosegundos, por isso necessito converter para segundos, para isso fiz $8397888*10^{-9} = 0.008397888sec$, por fim para se obter o resultado pretendido (*Kb/sec*) fiz: 10244/0.008397888 = 1219830.5098 Kb/sec. Como podemos verificar este valor encontra-se muito proximo do valor obtido com o *Benchmark IOZone* (1219830.5098 $\simeq 1223574$).

Com isto podemos concluir que o *Benchmark IOZone* inicia a contagem do tempo sempre que executa a *syscall open* e termina sempre que executa a *syscall close*. A contagem dos *Bytes* lidos é feita sempre à saída (*return*) da *syscall read*.

5.4. Read e Reread - Testado na diretoria diskHitachi

Para testar o *Benchmark IOZone* no disco HDD (*diskHitachi*) tive de correr o seguinte comando, de referir que tive de usar a *flag -f* para redirecionar o ficheiro temporário para o disco referido.

```
/opt/csw/bin/iozone -f /diskHitachi/a57779/iozone.tmp -i0 -i1 -s10m
```

O *output* da execução deste comando foi o seguinte:

```
File size set to 10240 kB

Command line used: /opt/csw/bin/iozone -f /diskHitachi/a57779/iozone. ←

tmp -10 -11 -310m

Output is in kBytes/sec

Time Resolution = 0.000001 seconds.

Processor cache size set to 1024 kBytes.

Processor cache line size set to 32 bytes.

File stride size set to 17 * record size.

kB reclen write rewrite read reread

10240 4 117760 603490 1356985 1521537
```

Em simultâneo foi executado a seguinte *script D*, de maneira a fazer o traçado dinâmico do comando em cima especificado. De referir mais uma vez que no predicado em que verifico o *path* (*self->path*) também tive de por a diretoria do disco em causa.

```
#!/usr/sbin/dtrace -s
#pragma D option quiet

syscall::open*:entry
/execname=="iozone" & uid==29231/
{
        self->path = copyinstr(arg1);
        self->path==r/diskHitachi/a57779/iozone.tmp" /
        self->path=="/diskHitachi/a57779/iozone.tmp" /
        self->start_time = timestamp;
        total_time=0;
        size = 0;
        flag = 1;
        total_time_io = 0;
}
syscall::read:return
//self->start_time> 0/
{
        self->r_size = (arg0/1024);
        size = size + self->r_size;
}
syscall::close*:entry
//self->path=="/diskHitachi/a57779/iozone.tmp" /
```

```
{
    self->stop_time = timestamp;
    self->elapsed = self->stop_time - self->start_time;
    dotal_time = total_time + self->elapsed;
    printf("%-12x %s\n", "SIZE", "ELAPSED TIME");
    printf("%-12d %d\n", size, total_time);
    dlag = 0;
}
```

sendo que o seu output foi o seguinte:

```
SIZE
                   ELAPSED TIME
0
SIZE
0
                   59568
ELAPSED TIME
                   6010
SIZE
0
SIZE
                   ELAPSED TIME
                                                                                                                        5
6
7
8
9
10
11
12
13
14
                   452529670
                   905072189
SIZE
0
SIZE
                   167244259
                  ELAPSED TIME
10244
                  7771309
                  ELAPSED TIME
6939257
```

Ao analisarmos os dados da mesma maneira que analisei em cima, isto é fazendo os mesmos cálculos que efectuei em cima, obtive os seguintes resultados:

```
• Tempo: 7771309 * 10^{-9} = 0.007771309sec
• Kb/sec: 10240/0.007771309 = 1318182.0463Kb/sec
```

Como podemos verificar o valor calculado encontra-se muito proximo do valor obtido com o *Benchmark IOZone* (1318182.0463 $\simeq 1356985$).

5.5. Tabela com todos os Resultados Obtidos

Apresento na tabela 1 todos os resultados obtidos para todos os testes realizados neste trabalho, quer para o *Benchmark IOZone* quer para a *Ferramenta Dtrace*.

Q						
0			Write	Rewrite	Read	Reread
10	SSD (Teste Home (ZFS))	IOZone	179488 Kb/sec	391934 Kb/sec	1223574 Kb/sec	1247709 Kb/sec
		Dtrace	200994.49091 Kb/sec		1219830.5098 Kb/sec	
	HDD (Teste /diskHitachi (UFS))	IOZone	126864 Kb/sec	340835 Kb/sec	1356985 Kb/sec	1521537 Kb/sec

| Dtrace | 137997.08869 Kbsec | 1318182.0462
Tabela 1. RESULTADOS OBTIDOS PARA IOZONE, DTRACE PARA DISCOS
SSD E HDD PARA AS CHAMADAS AO SISTEMA WRITE (REWRITE),
READ (REREAD)

Ao analisar a tabela 1 posso concluir que os resultados obtidos para um disco SSD (teste *Home*), para um sistema de ficheiros ZFS, para operações de escrita (*write* (*rewrite*)) são resultados, ligeiramente mais altos do que aqueles que foram obtidos para um disco HDD (teste /diskHitachi), com um sistema de ficheiros UFS.

Em termos de operações de leitura (*read* (*reread*)) tanto para o disco SSD como para o disco HDD, os resultados são semelhantes, sendo que para o disco HDD os resultados são um pouco mais altos, resultados estes que vão um pouco mais altos, resultados estes que vão um pouco mais melhor desempenho do que os discos SSD tem um melhor desempenho do que os discos HDD, como tal tenho algumas dificuldades em explicar este facto, uma vez que sisto acontece tanto na execução do *Benchmark IOZone* como com as *scripts Dtrace*. De referir que na operação de releitura (*Rewrite*), os resultados apresentados apresentam um melhor desempenho relativamente à operação de leitura, isto deve-se ao facto de o Sistema Operativos manter em cache

dados de ficheiros que foram lidos recentemente, como tal o acesso a esses dados é mais rápido.

Nas operações de re-escrita, acontece exatamente o mesmo, isto é, esta apresenta um melhor desempenho comparativamente à operação de escrita, isto porque, a primeira vez que se escreve num ficheiro, para além dos dados também são escritos meta-dados, o que não acontece na operação de re-escrita, uma vez que não é necessário escrever os meta-dados de novo.

6. Conclusão

Numa primeira abordagem a este trabalho, decidi explorar bem o *IOZone Benchmark*, realizando vários testes, com várias *flags*, por forma a perceber bem o funcionamento deste *Benchmark*. Para além da realização destes testes, ainda usei a ferramenta *truss* de forma a perceber qual o comportamento desta aplicação, isto é, que chamadas ao sistema utiliza, quantas vezes são feitas, quantas operações de escrita/leitura são feitas, entre outras análises.

Nesta fase do trabalho a maior dificuldade com que me deparei, foi essencialmente com a análise dos resultados resultantes do comando *truss*, uma vez que, quando executava o comando *truss*, para o *IOZone*, para um determinado tamanho de ficheiro, com um determinado *Record Size*, estava à espera de um resultado (no meu caso, um determinado numero de operações de escrita) e na verdade o resultado era um que não estava à espera, situação que para já não consigo perceber bem.

Na segunda parte deste trabalho desenvolvi *scripts* em *D*, que depois de usadas com a *Framework Dtrace*, produziram resultados semelhantes aos resultados obtidos com o *Benchmark IOZone*. Depois de obtidos esses resultados comparei os dois e pude concluir que, estes são semelhantes. Nesta fase a maior dificuldade com que me deparei foi em perceber como iria fazer as provas na *script D* de forma a obter os resultados que desejava, para ultrapassar essa dificuldade tive de analisar melhor o *output* do comando *truss*, por forma a perceber ainda melhor o comportamento do *Benchmark*.

Como trabalho futuro, gostava de melhorar as *scripts* que desenvolvi de maneira a conseguir obter resultados mais precisos. Também gostava de desenvolver algumas *scripts*, que na minha opinião, também seriam relevantes para este trabalho.

Referências

- [1] Active benchmarking. http://www.brendangregg.com/activebenchmarking.html.
- [2] Benchmark (computação). https://pt.wikipedia.org/wiki/Benchmark.
- [3] W. D. Norcott. Iozone filesystem benchmark.